Rapport försäkringskostnader

Malin

2026-04-20

Försäkringsanalys

Syftet med denna analys är att undersöka vilka faktorer som påverkar försäkringskostnaderna mest. Datasetet innehåller information om kunder, livsstilsfaktorer och hälsorelaterade variabler, och analysen fokuserar på att identifiera mönster och samband i datan.

Rapporten inleds med en beskrivande analys för att få en överblick över datan, följt av en regressionsanalys för att undersöka vilka variabler som bäst förklarar kostnadsskillnaderna mellan kunder. Målet är att ge ett underlag för framtida prissättning.

1. Dataförståelse

Datasetet består av 1100 kunder med 14 variabler som beskriver demografiska egenskaper, livsstilsfaktorer och försäkringskostnader. Medelåldern är 42.5 år och medelkostnaden uppgår till cirka 10 060 kr med en stor spridning, vilket indikerar att kostnaderna inte är normalfördelade.

Två variabler har saknade värden, bmi (28 observationer) och annual_checkups (20 observationer). Variabeln exercise_level har dessutom 22 tomma strängar som behöver konverteras till saknade värden.

Flera variabler lagras som text men är kategoriska till sin natur, exempelvis smoker, sex och region, och behöver konverteras till faktorer innan analysen. Inkonsekvent kapitalisering förekommer också och behöver hanteras.

Majoriteten av kunderna är icke-rökare och könsfördelningen är relativt jämn. Variablerna prior_accidents och prior_claims har medelvärden nära noll, vilket tyder på att skador och skadeanmälningar är ovanliga i kundstocken.

2. Datastädning och förberedelser

I datastädningen har inkonsekvent kapitalisering och eventuella blanksteg hanterats. Textvariabler har gjorts om till faktorer för att underlätta användningen i regressionsanalysen. Variablerna exercise_level och plan_type har dessutom gjorts om till ordnade faktorer. annual_checkups har gjorts om från decimaltal till heltal. Variabeln customer_id har tagits bort då den inte kommer användas i analysen.

En ny variabel för BMI-kategorier har skapats baserad på WHOs definitioner för att göra det tydligare hur detta kopplar till hälsa. Ytterligare nya variabler som åldersgrupp och risknivå övervägdes men bedömdes inte tillföra något utöver de befintliga variablerna i analysen.

3. Beskrivande analys

Könsfördelningen är jämn och regionsskillnaderna är små. Nedan visas de variabler som har tydligast samband med försäkringskostnaderna.

Kostnadsfördelning

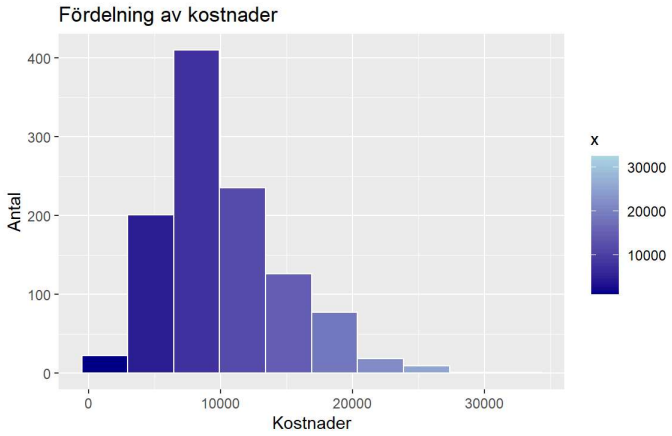

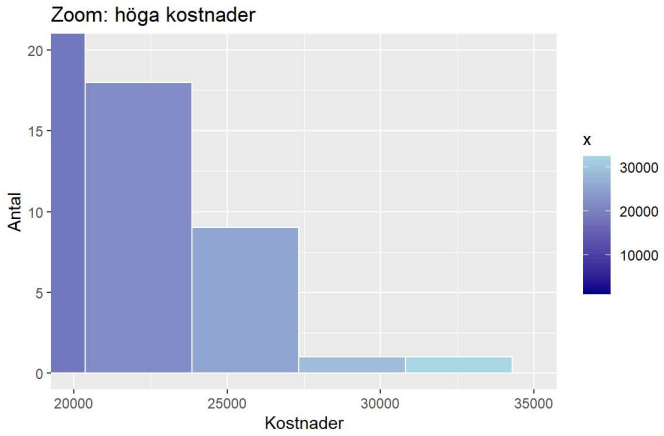

Tolkning av kostnadsfördelning

Kostnadsfördelningen är högersnedad med de flesta kunder i intervallet 5 000–15 000 kr. Zoom-grafen visar att ett fåtal kunder har mycket höga kostnader över 25 000 kr, vilket kan påverka modellens precision.

Kostnader vs rökning och ålder

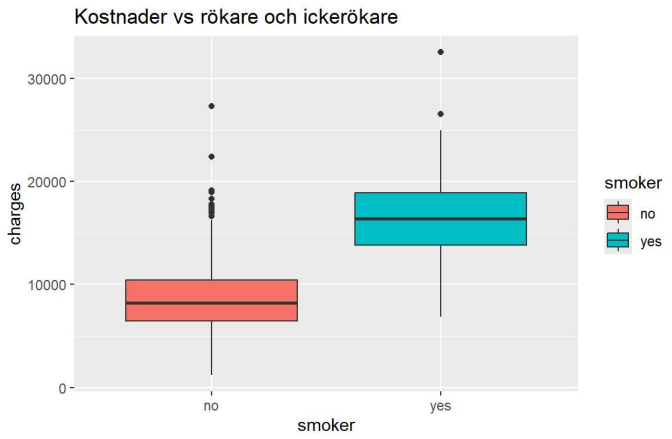

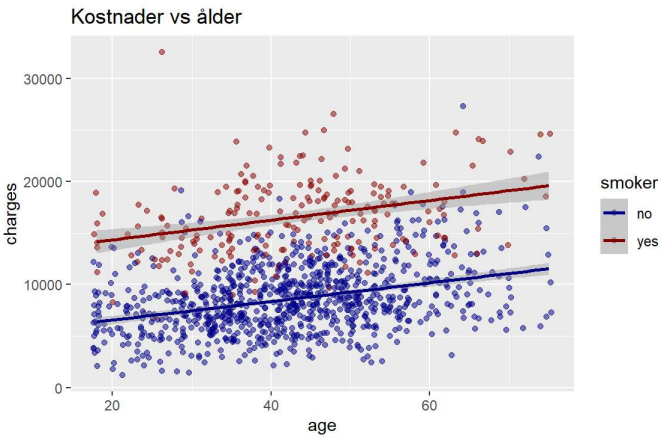

Tolkning kostnader vs rökning och ålder

Rökare har tydligt högre kostnader med en median runt 16 000 kr jämfört med cirka 8 000 kr för icke-rökare.

Det finns ett positivt samband mellan ålder och kostnader, där äldre kunder tenderar att ha högre kostnader. Rökare (röda punkter) ligger genomgående högre än icke-rökare oavsett ålder.

Trendlinjerna visar att kostnader ökar med ålder för båda grupperna, men rökare har genomgående högre kostnader oavsett ålder.

4. Regressionsanalys

Urvalet av prediktorer baseras på den beskrivande analysen och korrelationstabellen. Rökning inkluderas då boxplotanalysen visade att rökare har nästan dubbelt så höga kostnader som icke-rökare, vilket är den tydligaste skillnaden i hela datasetet. Ålder och tidigare olyckor inkluderas eftersom de hade starkaste korrelationerna med försäkringskostnaderna (0.26 respektive 0.24). Tidigare skadeanmälningar (0.18) och BMI (0.15) inkluderas som hälso- och riskrelaterade variabler med lägre samband.

Kön och region utesluts då boxplotanalysen visade minimala skillnader mellan grupperna. Antal barn och årliga hälsokontroller utesluts på grund av mycket svaga korrelationer (0.03 respektive 0.06). Träningsnivå och försäkringsplan utesluts från grundmodellen men testas i en utökad modell för att undersöka om de förbättrar förklaringsgraden.

Modelljämförelse

Modelljämförelse

modell	r_squared	adjusted_r_squared	residual_se
Modell 1	0.586	0.585	2945.348
Modell 2	0.749	0.747	2305.575

Tolkning modelljämförelse

Modell 2 är mer lämplig än modell 1. R^2 ökar från 0.587 till 0.749, vilket innebär att den utökade modellen förklarar ytterligare 16 procentenheter av variationen i försäkringskostnaderna. Residualstandardfelet minskar från 2 945 till 2 306, vilket innebär att modellens genomsnittliga fel minskar med cirka 640 kr per kund.

De linjära komponenterna av träningsnivå, försäkringsplan och kronisk sjukdom är statistiskt signifikanta, vilket bekräftar att det var motiverat att inkludera dem i modell 2. De kvadratiska komponenterna av de ordnande variablerna (exercise_level.Q och plan_type.Q) är däremot inte signifikanta, vilket tyder på att sambanden är linjära snarare än böjda, vilket är förväntat för dessa variabler.

Faktiska vs predikterade kostnader (modell 2)

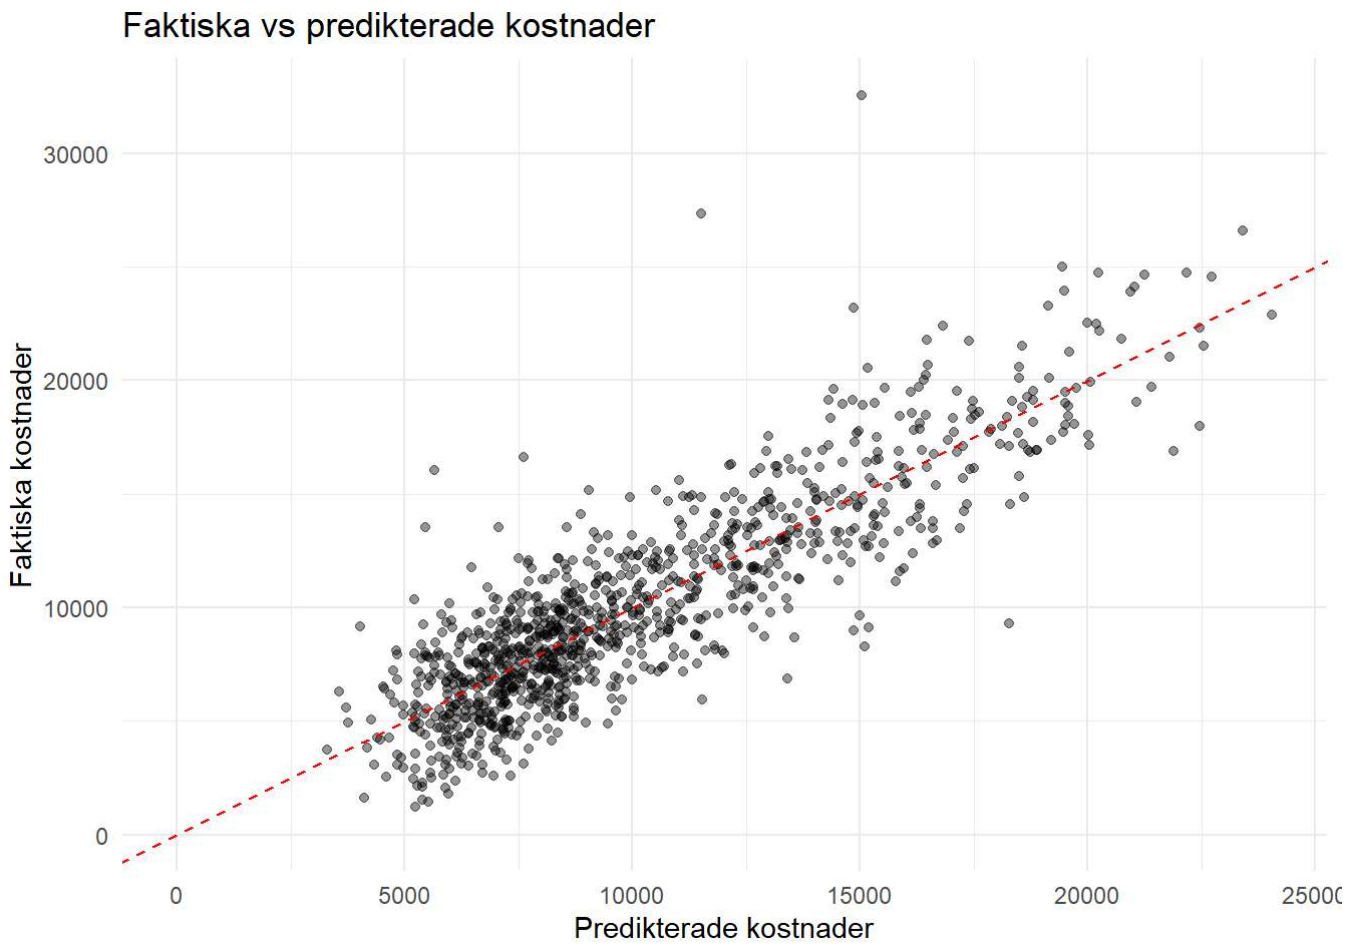

Tolkning faktiska vs predikterade kostnader (modell 2)

Punkterna följer den röda linjen relativt väl, vilket indikerar att modellen har god anpassning. Den röda linjen representerar perfekt anpassning, dvs. där faktiska och predikterade kostnader är lika. Vid höga predikterade värden ökar spridningen något, vilket tyder på att modellen är något sämre på att förutsäga kostnader för de dyraste kunderna.

Sammanfattning av regressionsanalysen

Rökning är den starkaste prediktorn – rökare har i genomsnitt 7 467 kr högre kostnader än icke-rökare. Kronisk sjukdom är den näst starkaste faktorn med 3 780 kr högre kostnader. Högre träningsnivå är associerat med lägre kostnader (-1 020 kr) och högre försäkringsplan med högre kostnader. Ålder, BMI, tidigare olyckor och skadeanmälningar bidrar alla signifikant men med mindre effekter.

Det är värt att notera att koefficienten för tidigare skadeanmälningar sjunker från 1 317 i modell 1 till 902 i modell 2, vilket tyder på att en del av effekten i modell 1 egentligen förklaras av träningsnivå, försäkringsplan och kronisk sjukdom.

Styrkor:
- Modellen förklarar 75% av variationen, vilket är starkt för verkliga data
- Resultaten följer rimliga mönster – faktorer som rökning och kronisk sjukdom driver kostnader uppåt, vilket stämmer med vad man kan förvänta sig
- Modellen kan användas som beslutsstöd vid framtida prissättning av liknande kunder

Svagheter och begränsningar:
- 49 observationer togs bort på grund av saknade värden
- Multikollinearitet mellan prediktorerna har inte undersökts
- Modellen fångar endast linjära samband
- Datasetet saknar variabler som rökarhistorik och socioekonomisk status

En möjlig förbättring av modellen vore att undersöka interaktionseffekter, t.ex. mellan BMI och träningsnivå, då trendlinjerna i figuren “Kostnader vs BMI” antyder att BMI påverkar kostnader olika beroende på träningsnivå.

5. Slutsatser

Analysen visar att rökning och kronisk sjukdom är de faktorer som tydligast driver försäkringskostnaderna, följt av ålder, BMI och tidigare olyckor och skadeanmälningar. Regressionsmodellen förklarar 75% av variationen i kostnaderna och bedöms kunna användas som beslutsstöd vid framtida prissättning.

Modellen fångar dock inte icke-linjära samband eller interaktionseffekter mellan variabler. Datasetet saknar också information som rökarhistorik och socioekonomisk status, vilket troligen påverkar kostnaderna i verkligheten.

Möjliga förbättringar inkluderar att undersöka interaktionseffekter, hantera de saknade värdena mer systematiskt samt komplettera datasetet med fler relevanta variabler.

6. Självreflektion

En styrka i arbetet är att datastädningen är noggrann och välmotiverad, och att valet av prediktorer baseras på både visualiseringar och korrelationsanalys. Regressionsanalysen innehåller två modeller med fullständig diagnostik och kritisk diskussion.

Det mest utmanande momentet var att tolka koefficienterna för de ordnade faktorerna och förstå hur förklaringskraften förändrades mellan modellerna där särskilt koefficienten för prior_claims skiljde sig mycket mellan modellerna.

Arbetet uppfyller enligt min bedömning kraven för VG, eftersom det inkluderar modeljämförelse, residualdiagnostik samt kritiskt resonemang kring modellens styrkor, begränsningar och möjliga förbättringar.